

# Agent 落地范式与案例



## Agent 基础范式

<https://mp.weixin.qq.com/s/YNXJKKL-KmQ3gsBBJ2Zypw>

|                                                                                           |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
|-------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div>工具调用型 Agent</div> <div>openai-agents</div> <div>langchain</div> <div>常规的 Agent</div> | <div>Agent 直接执行，执行完返回结果。没有多轮对话，没有复杂规划，核心在于精准理解意图并调用正确的工具。</div> <div><ul style="list-style-type: none"><li>• <b>第一步是函数注册。</b>你需要提前把所有可调用的函数描述喂给 LLM。每个函数包括三部分：函数名、参数定义、功能描述。这些信息会注入到 System Prompt 里。模型看到这些描述后，就知道自己有哪些工具可以用。</li><li>• <b>第二步是意图识别。</b>用户提问后，LLM 先判断这个问题需不需要调用函数。如果是闲聊类问题，直接回答；如果涉及外部数据，决定调用哪个函数、传什么参数。</li><li>• <b>第三步是结构化输出。</b>LLM 不返回自然语言，而是返回一段 JSON，包含函数名和参数。</li><li>• <b>第四步是执行与回填。</b>你的后端拿到这个 JSON，调用真正的 API，把结果再喂回给 LLM，让它组装成自然语言返回给用户。</li></ul></div> <div><div><div><div>工具调用型 Agent 流程</div><div><div><div>用户输入</div><div>LLM 解析</div><div><div><div>{ "function": "...",<br/>"arguments": {...} }</div></div></div><div>后端执行 API</div><div>结果回填</div><div>自然语言输出</div></div><div><div>① 解析意图</div><div>② 生成调用指令</div><div>③ 执行并组装回答</div></div></div></div></div></div> |
| <div>意图路由型 Agent</div>                                                                    | <div>判断用户到底想干嘛，然后把请求路由到对应的下游模块。它本身不执行任何业务逻辑，只做分诊台。</div> <div><ul style="list-style-type: none"><li>• 用户提问进来，路由 Agent 先做意图分类，判断属于哪个大类。可能的结果包括日程类、知识类、写作类、数据类、审批类、闲聊类。判断完之后，把请求连同上下文一起转发给对应的下游模块处理。</li><li>• 意图分类要穷尽，漏掉一个意图用户体验就塌了。建议用 Embedding 相似度做粗筛，LLM 做精分，这样又快又准。必须有其他兜底意图，用户说的话不在预设范围怎么办。</li></ul></div> <div><div><div><div>意图路由型 Agent 流程</div><div><div><div>用户输入</div><div>意图路由器</div><div><div>日程模块</div><div>知识库模块</div><div>写作助手模块</div></div><div>统一输出</div></div></div></div></div></div>                                                                                                                                                                                                                                                                                                |

|                        |                                                                                                                                                                                                                                                                                                                                                                                              |
|------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div>任务执行 Agent</div>  | <div>给个输入、出个结果，不需要多轮交互。这类 Agent 的核心是把任务定义清楚，执行到位，一次搞定。</div> <div><ul style="list-style-type: none"><li>定义任务类型和输出格式，用户输入内容，LLM 按照任务要求处理，返回结果。没有中间状态，没有多轮交互，一来一回搞定。</li><li>入输出格式必须标准化，提前定义好 schema 方便后续自动化流程对接。</li></ul></div> <div><div>一次性任务执行 Agent 流程</div><div><div>用户输入</div><div>任务处理器<br/>翻译/摘要/生成</div><div>结构化输出</div></div></div>                                                |
| <div>知识检索型 Agent</div> | <div>RAG，Retrieval-Augmented Generation，检索增强生成。核心逻辑是回答问题前先从知识库检索相关资料，再基于资料生成回答。<b>第一步</b>是用户提问，Agent 把提问向量化。<b>第二步</b>是在向量库里检索最相关的 Top-K 文档片段，通常取 5 到 10 条。<b>第三步</b>是把这些文档片段拼接到 Prompt 里，让 LLM 基于这些资料生成回答。</div> <div><div>知识检索型 Agent (RAG) 流程</div><div><div>用户提问</div><div>问题向量化</div><div>向量库检索<br/>Top-K 相关文档</div><div>检索到的文档片段</div><div>LLM 生成回答</div><div>带来源的回答</div></div></div> |


|                                                                              |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |
|------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div>表单填写型 Agent</div> <div>发件人、收件人</div> <div>收货地址</div> <div>电话、快递方式</div> | <div>引导用户一步步填完一张表单，而不是让用户自己对着表单傻填。核心在于用对话的方式收集结构化信息。首先定义表单的字段结构和每个字段的收集话术。然后 Agent 按照字段顺序逐个询问，用户回答后 Agent 提取信息填入对应字段。如果用户回答模糊或有歧义，Agent 追问确认。所有必填字段收集完毕后，Agent 汇总确认，用户确认无误后提交。</div> <div data-bbox="889 325 1719 926"><p><b>表单填写型 Agent 流程</b></p><pre>graph TD; A[对话引导收集信息] --&gt; B[State: 已收集字段]; B -- 追问缺失信息 --&gt; A; B --&gt; C[汇总确认并提交];</pre></div>                                                                                                                                                                   |
| <div>计划 - 执行型 Agent</div>                                                    | <div>Agent 先生成一个执行计划，然后逐步执行每个步骤。规划和执行分离，计划可审核可修改。计划 - 执行型 Agent 会先生成一个 Step-by-Step 的计划，比如：<b>第一步收集抖音的核心功能，第二步收集快手的核心功能，第三步对比两者差异，第四步总结分析报告</b>。计划生成后，Agent 按顺序执行每一步，执行完汇总返回。</div> <div>工作流程分两阶段。第一阶段是规划阶段，Agent 接收任务后调用规划模块生成执行计划，通常 3 到 7 步。第二阶段是执行阶段，Agent 逐步执行每个步骤，每步可能是调用工具、检索资料或生成内容，执行完进入下一步。</div> <div data-bbox="840 1306 1766 1877"><p><b>计划-执行型 Agent 流程</b></p><pre>graph TD; A[复杂任务] --&gt; B[规划模块]; B --&gt; C[执行计划: Step1→Step2→Step3]; C --&gt; D[执行模块]; D --&gt; E[工具/LLM]; E -- 循环执行 --&gt; D;</pre></div> |

|                   |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
|-------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>链式推理 Agent</p> | <p>CoT, Chain of Thought, 思维链。核心是让 Agent 在最终回答前先输出中间推理过程，边想边做。计划 - 执行型是先想完再做，规划和执行是两个独立阶段。链式推理是边想边做，每一步推理直接产出中间结果，下一步基于上一步的结果继续推理。更适合那种需要逐步计算或逐步推导的任务。</p> <p>用户提问后，Agent 不直接给答案，而是先输出第一步推理，然后基于第一步的结果输出第二步推理，一直到得出最终答案。整个推理过程是线性的，每一步都有明确的输入输出。</p> <div data-bbox="479 485 2129 877"><h3>链式推理 Agent (CoT) 流程</h3><pre>graph LR; A[问题输入] --&gt; B[推理步骤1<br/>阶段结论]; B --&gt; C[推理步骤2<br/>阶段结论]; C --&gt; D[推理步骤3<br/>阶段结论]; D --&gt; E[最终答案];</pre></div> |
| <p>反思型 Agent</p>  | <p>Agent 在生成回答后会自己检查一遍我刚才说的对不对，如果发现问题会自动修正。核心是引入自我批评机制提升输出质量。</p> <p><b>第一步</b> Agent 生成初步回答。<b>第二步</b>调用评审模块检查回答，评审模块会给出通过或不通过的判定，不通过要说明哪里有问题。<b>第三步</b>如果不通过，Agent 根据评审意见重新生成，回到第二步继续检查，直到通过或达到最大迭代次数。</p> <div data-bbox="974 1211 1632 1738"><h3>反思型 Agent 流程</h3><pre>graph TD; A[生成回答] --&gt; B[自检评审]; B --&gt; C{通过?<br/>是/否}; C -- 是 --&gt; D[输出结果]; C -. 否: 重新生成 .-&gt; A;</pre></div>                                                        |

递归分解型 Agent

Agent 会先把大问题拆成小问题，解决完小问题后再综合回答大问题。核心是问题的层层分解和自底向上的答案汇总。计划 - 执行型的计划是一条线，Step1 到 Step2 到 Step3 顺序执行。递归分解型更像一棵树，一个大问题拆成 3 个子问题，每个子问题可能还要继续拆分，形成多层结构。解决完所有叶子节点的问题后，再自底向上汇总答案。

用户提出复杂问题，Agent 先判断这个问题能不能直接回答。如果不能，就拆分成若干子问题分别处理。每个子问题递归执行同样的逻辑，直到问题简单到可以直接回答。最后把所有子问题的答案汇总成最终答案。



|             |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |
|-------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 记忆增强型 Agent | <p>普通 Agent 每次对话都是从零开始，不记得上一次聊了什么。这类 Agent 有持久化的记忆模块，可以记住用户偏好、历史操作、上下文背景。</p> <p>用户提问后，Agent 先从记忆库检索相关的历史信息作为上下文。然后基于当前问题加历史上下文生成回答。回答完后，Agent 判断这次对话有没有值得记住的信息，有的话写入记忆库。</p> <p><b>设计要点有几个。记忆要分类</b>，短期记忆管当前会话，长期记忆管用户档案，情景记忆管历史事件。<b>检索和存储要异步</b>，不能让记忆操作拖慢响应速度。必须有遗忘机制，存太多了检索效率会下降，要有优先级淘汰策略。<b>隐私要考虑</b>，哪些信息可以记、记多久、用户能不能删除，都要设计清楚。</p> <div><p>记忆增强型 Agent 流程</p><pre>graph LR; A[用户提问] --&gt; B[记忆检索]; B -.-&gt; C[记忆库]; B --&gt; D[LLM 生成]; D --&gt; E[回复用户]; D -.-&gt; F[记忆更新];</pre></div> |
|-------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

## Agent 应用范式


<https://mp.weixin.qq.com/s/wtGJUQKy4za8Q-mKtF5Og>

Coding Agent

编程 Agent 是当前生态里最热、商业化最快的工种，代表产品是 Cursor、Claude Code、Devin、Windsurf、GitHub Copilot Workspace。

类比是程序员同事，给它仓库访问权限和需求描述，它自己读代码、改代码、跑测试、提交 PR，24 小时不下班、不抱怨。

工作环境是代码仓库加终端加浏览器三件套，Cursor 把整个 IDE 都变成 Agent 工作台就是这个原因。核心机制是读代码、改代码、跑测试、看结果、决定下一步的循环，Devin 一度宣称能跑 8 小时不停，靠的就是这个循环的稳定性。



Browse Agent

浏览器 Agent 是替你点网页的工种，代表产品是 OpenAI Operator、Browser Use、Manus、智谱 AutoGLM、Skyvern。类比是网络数据录入员，给它一个任务从京东找出销量前十的扫地机器人，把价格、评分、品牌录到表里，它自己开浏览器、搜关键词、翻页、点详情、抓数据、填表，全程不用动手。

工作环境就是一个无头浏览器，模型看到的不是网页本身，而是截图加 DOM 结构。核心机制是截屏、决策、动作、验证的循环，一个完整任务可能要跑几十甚至上百轮，任何一轮卡住整个任务就崩。

真正的壁垒不在模型多聪明，在恢复力多强，网页改一次 Agent 就崩，淘宝今天换个按钮位置，Agent 明天就找不到了。能不能识别走错、回到正确路径，才是工程化的关键能力。




Deep Research

研究 Agent 是替你写报告、做研究的工种，代表产品是 OpenAI ChatGPT Deep Research、Perplexity Pro、Google Gemini Deep Research、xAI Grok DeepSearch。

类比是实习研究员，你给一个研究问题，它自己拆问题、跑搜索、读资料、整理观点，产出一份带引用的报告。过去研究员花一天的活，五分钟搞定，每个观点都标好出处。

工作环境是搜索引擎加网页阅读加文档处理，一次任务可能跑 30 到 100 次搜索，读几百个页面。核心机制是一条长链路：把问题拆成子问题→每个子问题各自搜→读相关页面→按子问题归类→综合成报告并标来源。

链路里任何一步出错，报告质量都会打折。质量瓶颈不在模型聪不聪明，在这条链路跑得稳不稳。同一个 Claude 模型，在 Perplexity 和普通聊天框里跑研究任务，质量差距巨大，全部来自链路工程，不是模型本身。



Computer Use

电脑 Agent 是直接控制整台电脑的工种，代表产品是 Anthropic Claude Computer Use、OpenAI ChatGPT Agent、Google Project Mariner。类比是远程技术支持，把屏幕分享给一个远程技术员，他能看到全部内容，能控制鼠标键盘帮你完成任务，只是把人换成了模型。

工作环境是一整台电脑，可以是 Windows、macOS、Linux 或云端虚拟机。模型的输入是屏幕截图，输出是鼠标坐标加点击加键盘按键。和浏览器 Agent 都跑截屏、决策、动作、验证的循环，差异在于电脑 Agent 没有 DOM 这一语义层，纯靠像素识别按钮、输入框、菜单在哪里，精度大幅下降。

### 浏览器智能体

 **输入：** 截图加网页结构

 **输出：** 点击坐标加键盘输入

〇〇〇 < >

网站标题

首页 产品 价格 帮助

搜索内容...

搜索



推荐链接


了解更多 > 立即购买 > 查看详情 >

提交

### 电脑智能体

 **输入：** 仅截图

 **输出：** 鼠标坐标加键盘输入



 **电脑智能体更难，因为没有结构层。**

数据分析 Agent 是替你处理数据、出图、出洞察的工种，代表产品是 ChatGPT Data Analyst、Julius AI、Hex Magic、Anthropic Claude with Code Interpreter。类比是数据分析师，给它一份 Excel 或 CSV 加一句我想看什么，它自己跑统计、画图、出结论。过去要数据团队排期一周的活，产品经理自己一小时就能拿到第一版。

工作环境是 Python 沙盒加数据文件加可视化库，核心机制是 Code Interpreter 加数据探索循环：写代码、跑、看结果、改代码再跑，直到满意。这个循环里数据探索能力远比写代码能力关键。



创意生成 Agent 是替你出图、出视频、出 UI 的工种，代表产品是 v0、Krea、Recraft、即梦、Sora 系列、Midjourney 的 Agent 化版本。类比是设计师或视频剪辑师，你描述风格和内容，它自动生成。和早期生成模型的差别是，创意 Agent 不再一次出图，而是支持多轮编辑、迭代、组合，可以来回调整直到满意。

工作环境是画布加生成模型加提示词管理，核心机制是多模态模型加多轮编辑加反馈循环。你说把人物的衣服换成红色，Agent 知道你指的是上一张里那个人物，而不是从零开始，这种连续性是 Agent 形态和工具形态的本质区别。



客服 Agent 是 24 小时在线的坐席工种，代表产品是 Intercom Fin、Salesforce Agentforce、Sierra、Decagon。类比是客服坐席，客户问问题，Agent 先去知识库查，能答直接答，不能答升级到工单让人接手。对客户来说就是和一个客服在聊，只是这个客服永远不下班、不烦躁、不出错、不离职。


工作环境是客服系统加 CRM 加内部知识库加工单系统，核心机制是 RAG 检索加多轮对话状态加工单升级判断三块，找答案、记住客户上一句话、识别什么时候该把对话交给给人。



智能外呼

销售外呼 Agent 是替你做线索跟进、邮件外联、电话开发的工种，代表产品是 11x、Outreach AI、Apollo AI、Clay。类比是 AI SDR，即销售开发代表，给它一份客户名单，它自动写个性化邮件、跟 LinkedIn 消息、安排会议、把有意向客户转给真人销售。Agent 自己跑完一万条线索只用一个夜晚。

工作环境是 CRM 加邮件系统加 LinkedIn 加会议系统，核心机制是潜在客户研究加多渠道触达加 CRM 写回。潜在客户研究扫描客户的 LinkedIn、公司动态、公开演讲，提炼钩子；多渠道按顺序在邮件、LinkedIn、电话上跟进；CRM 写回把每次互动沉淀成结构化数据。



语音交互

语音 Agent 是把语音能力做成 Agent 基础设施的工种，代表产品是 Retell AI、ElevenLabs Voice、Bland AI、Vapi、Synthflow。类比是 24 小时不下班的电话坐席。和销售外呼 Agent 的区别是，它不绑定单一业务场景，而是一层能力，医疗预约、酒店预订、保险理赔、客服热线、教育跟进、外呼营销都能用，一家 Bland AI 同时跑五个场景。

工作环境是电话系统加语音模型加业务知识库，核心机制是 ASR 加 LLM 加 TTS 的实时流式管道：ASR 把用户的话转成文字，LLM 决定怎么回应，TTS 把回应变成人声。三块都要支持流式，边接收边处理，任何一块卡半秒，整段对话就像机器人。




具身智能

具身 Agent 是把 Agent 装进物理身体的工种，代表产品是 Figure 02、1X Neo、Tesla Optimus、银河通用 G1、智元远征 A2。

类比是真正进入物理世界的员工，前面十类都在屏幕里干活，具身 Agent 是第一类需要动手动脚的员工，在工厂、家庭、餐厅、仓库里搬箱子、叠衣服、拧螺丝。

工作环境是物理世界。输入是摄像头画面加传感器读数加语音指令，输出是关节角度加电机转速加抓握力度，IO 比前面十类都复杂，物理世界不能被精确建模，有重力、有摩擦、有不可预测的扰动。




意图识别与对话

[https://mp.weixin.qq.com/s/zYZVXg\\_eMKXbrMLSyg8GJg](https://mp.weixin.qq.com/s/zYZVXg_eMKXbrMLSyg8GJg)

**OOD**（Out-of-Domain，域外问题）就是用户问了一个系统没有预定义意图的问题。不是用户说错了，是系统没有这个功能但用户不知道。

1. 兜底回复。"没听明白您要做什么，目前我可以帮您订票、查询、退改签"
2. 追问澄清。给候选意图让用户选：是要订票还是查询？
3. 转人工。复杂问题和高价值用户路由到人工
4. 大模型兜底。接通用大语言模型直接回答"北京到上海约 1300 公里"，再引导回订票主线



实体的概念明白了，接下来的问题是：系统怎么从一段话里找出这些实体？不是人工标注，是要让机器自动识别。这件事就叫 **NER**。

**NER** (Named Entity Recognition, 命名实体识别) 就是让系统自动从文字里找出哪些词是实体、分别是什么类型。




**NER** 识别出实体了，但计算机在内部是怎么表示"明天是时间实体，北京是地点实体"的？靠的就是 **BIO 标注**，一套给每个字打标签的规则。

**BIO** 是 **NER** 模型内部的标注方案，用三种标签标记每个字：

- **B (Beginning)**，实体的第一个字
- **I (Inside)**，实体里除第一个字之外的其他字
- **O (Outside)**，不属于任何实体的字

BIO 标注：机器识别实体的底层方式



|   |                     |
|---|---------------------|
| B | = Beginning，实体的第一个字 |
| I | = Inside，实体内部的字     |
| O | = Outside，非实体的字     |

连续的 B + I 合并为一个完整实体

标准 **BIO** 体系每个字只能打一个标签，没法同时标注内外两层。常见处理方案：

1. 只保留外层实体，订票场景最常用的选择，实现最简单
2. 按粒度分两层处理，先识别大实体，再识别小实体，精度高但实现复杂
3. 用专门处理嵌套的模型，精度最高，工程成本也最高

时间表达里嵌套也很常见，"明天早上8点左右"就是三层：明天（日期）+ 早上（时段）+ 8点左右（大概的精确时间）。处理不好，归一化出来的时间段会出错。

站点实体（北京南站）



| 实体类型           | 订票场景下<br>优先级    |
|----------------|-----------------|
| 站点实体<br>(北京南站) | 外层优先<br>(优先级：1) |
| 地点实体<br>(北京)   | 内层次要<br>(优先级：2) |

地点实体（北京）


实体消歧就是在发现歧义后，利用上下文把候选答案缩小到唯一一个的过程。

利用当前句子消歧：

- 用户说的是高铁，那北京大概率指北京南站（高铁 G/D 字头主要从北京南站发车）
- 用户说的是普速列车，那北京更可能是北京站

利用对话历史消歧：

- 第一轮用户说了订高铁，第三轮说"改个时间从北京出发"，北京继承上文，还是北京南站
- 用户上次订的是北京西站出发，这次再说"从北京出发"，可以优先匹配北京西站



实体归一化就是把用户说的话转换成系统能直接处理的标准格式。

| 用户原始表达 | 归一化结果       |
|--------|-------------|
| 明天     | 2026-04-28  |
| 早上8点左右 | 06:00到09:30 |
| 北京     | 北京南站BJP2    |
| 上海     | 上海虹桥AOH     |
| 高铁     | G字头车型       |
| 二等座    | 席别代码M       |

槽位就是意图执行所需的参数容器，提前定义好完成这个意图需要哪些信息。  
实体是提取出来的值，槽位是等待被填入的格子。

订票意图的完整槽位定义：

- 槽位[出发日期]，必填，缺失追问，接受时间实体
- 槽位[出发站]，必填，缺失追问，接受站点实体
- 槽位[到达站]，必填，缺失追问，接受站点实体
- 槽位[出发时间偏好]，选填，可忽略，接受时间范围实体
- 槽位[车型偏好]，选填，缺失默认全部，接受车型实体

每个槽位要定义三件事：必填还是选填、缺失时怎么处理、接受什么类型的实体。这些在写需求文档时就要写清楚，不是开发阶段再讨论的事。



多轮槽位积累就是跨多轮对话把槽位逐步填满的机制，每一轮的新信息都累积到同一个订单的槽位状态里。

实现多轮槽位积累的核心是：保存当前会话每个槽位的填充状态；每轮新的用户输入先匹配未填槽位，而不是重新识别意图；意图不变的情况下，槽位状态持续累积，不重置。



意图清单的颗粒度是产品设计阶段最重要的决策，不是技术问题，是业务问题。粒度太粗，订票和改签混成一类，出了问题追不到原因；粒度太细，每个意图的训练样本太少，模型训不好。意图识别就是让系统自动判断用户这句话属于哪个意图。本质是一个分类问题：输入一句话，输出一个意图标签和一个置信度分数。

1. 关键词匹配。写规则，订 / 买 / 预订 匹配订票意图，退票 / 退掉 匹配退票意图。好处是简单快，坏处是说法稍微变一下就抓不到，而且容易误命中（不退理由 也会命中退票规则）
2. 模型分类。用一个专门训练过的语言理解模型做分类，"明天我得去趟上海"这种隐式表达也能识别，需要标注数据
3. 大模型判断。直接把用户输入喂给大语言模型，让它判断意图，不需要训练，但速度慢、成本高，适合长尾场景或刚起步阶段

# Agent 基础工具

## Web Search

Web Search 让模型能够访问最新网络信息，并提供带有引用来源的回答。Web Search（网页搜索）功能之所以必要，核心在于解决大语言模型固有的局限性。

| 问题       | Web Search 解决方案    |
|----------|--------------------|
| 知识过时     | 实时检索最新信息           |
| 模型幻觉     | 基于真实数据回答 + 引用来源    |
| 无法验证     | 提供可点击的 URL 引用      |
| 缺乏本地化    | 支持地理位置设置           |
| 无法处理复杂研究 | Agentic 搜索 + 深度研究  |
| 需要实时数据   | 体育 / 天气 / 金融等实时信息源 |
| 合规要求     | 域名过滤、来源完整性         |

| Web Search 类型    | 说明                             | 适用场景        |
|------------------|--------------------------------|-------------|
| 非推理型搜索           | 模型直接传递查询给搜索工具，返回顶部结果，无内部规划     | 快速查找        |
| Agentic 搜索（推理模型） | 模型主动管理搜索过程，可在思维链中分析结果、决定是否继续搜索 | 复杂工作流       |
| 深度研究             | 专门的 agent 驱动方法，可访问数百个来源，运行数分钟  | 深度、长时间的研究任务 |

| Web Search 工具                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | 说明                                                                                |                    |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------|--------------------|----|---------------------------------------------------------------------------------------------|---------------------------------------------------|------------------|---------------------------------------------------------------------------------------------|---------------------------------------------------|--------------------|---------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------|--------------|----------------------|-------------|---------|-------------------------|
| <a href="https://developers.openai.com/api/docs/guides/tools-web-search">https://developers.openai.com/api/docs/guides/tools-web-search</a>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 对谷歌等英文内容支持友好，支持多种 Search 和内容总结方式。                                                 |                    |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
| <a href="https://platform.claude.com/docs/en/agents-and-tools/tool-use/web-search-tool">https://platform.claude.com/docs/en/agents-and-tools/tool-use/web-search-tool</a><br><a href="https://platform.claude.com/docs/en/agents-and-tools/tool-use/web-fetch-tool">https://platform.claude.com/docs/en/agents-and-tools/tool-use/web-fetch-tool</a>                                                                                                                                                                                                                                                                                                                                                                                                                                  | 对谷歌等英文内容支持友好，支持多种 Search 和内容总结方式。                                                 |                    |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
| <a href="https://docs.bigmodel.cn/cn/guide/tools/web-search">https://docs.bigmodel.cn/cn/guide/tools/web-search</a> <table><tr><th>搜索引擎编码</th><th>特性</th><th>价格</th></tr><tr><td>search_std</td><td>基础版（智谱AI 自研）：满足日常查询需求，性价比极高</td><td>0.01元/次</td></tr><tr><td>search_pro</td><td>高级版（智谱AI 自研）：多引擎协作显著降低空结果率，召回率和准确率大幅提升</td><td>0.03元/次</td></tr><tr><td>search_pro_sogou</td><td>搜狗：覆盖腾讯生态（新闻/企鹅号）和知乎内容，在百科、医疗等垂直领域权威性高</td><td>0.05元/次</td></tr><tr><td>search_pro_quark</td><td>夸克：精准触达垂直内容</td><td>0.05元/次</td></tr></table>                                                                                                                                                                                                                                                   | 搜索引擎编码                                                                            | 特性                 | 价格 | search_std                                                                                  | 基础版（智谱AI 自研）：满足日常查询需求，性价比极高                       | 0.01元/次          | search_pro                                                                                  | 高级版（智谱AI 自研）：多引擎协作显著降低空结果率，召回率和准确率大幅提升            | 0.03元/次            | search_pro_sogou                                                                            | 搜狗：覆盖腾讯生态（新闻/企鹅号）和知乎内容，在百科、医疗等垂直领域权威性高                                            | 0.05元/次      | search_pro_quark     | 夸克：精准触达垂直内容 | 0.05元/次 | 对中文内容支持友好，并且内容已经筛选和审核过。 |
| 搜索引擎编码                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                | 特性                                                                                | 价格                 |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
| search_std                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | 基础版（智谱AI 自研）：满足日常查询需求，性价比极高                                                       | 0.01元/次            |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
| search_pro                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | 高级版（智谱AI 自研）：多引擎协作显著降低空结果率，召回率和准确率大幅提升                                            | 0.03元/次            |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
| search_pro_sogou                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      | 搜狗：覆盖腾讯生态（新闻/企鹅号）和知乎内容，在百科、医疗等垂直领域权威性高                                            | 0.05元/次            |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
| search_pro_quark                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      | 夸克：精准触达垂直内容                                                                       | 0.05元/次            |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
| <table><tr><th>产品</th><th>API端口</th><th>描述</th></tr><tr><td> 读取器 API</td><td><a href="https://r.jina.ai">https://r.jina.ai</a></td><td>将 URL 转换为大模型友好文本</td></tr><tr><td> 读取器 API</td><td><a href="https://s.jina.ai">https://s.jina.ai</a></td><td>搜索网络并将结果转换为大模型友好文本</td></tr><tr><td> 向量模型API</td><td><a href="https://api.jina.ai/v1/embeddings">https://api.jina.ai/v1/embeddings</a></td><td>将文本/图片转为定长向量</td></tr></table><br><a href="https://jina.ai/api-dashboard/reader">https://jina.ai/api-dashboard/reader</a> | 产品                                                                                | API端口              | 描述 |  读取器 API | <a href="https://r.jina.ai">https://r.jina.ai</a> | 将 URL 转换为大模型友好文本 |  读取器 API | <a href="https://s.jina.ai">https://s.jina.ai</a> | 搜索网络并将结果转换为大模型友好文本 |  向量模型API | <a href="https://api.jina.ai/v1/embeddings">https://api.jina.ai/v1/embeddings</a> | 将文本/图片转为定长向量 | 稳定性较好，并且更加通用，但在国内不能用 |             |         |                         |
| 产品                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | API端口                                                                             | 描述                 |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
|  读取器 API                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | <a href="https://r.jina.ai">https://r.jina.ai</a>                                 | 将 URL 转换为大模型友好文本   |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
|  读取器 API                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | <a href="https://s.jina.ai">https://s.jina.ai</a>                                 | 搜索网络并将结果转换为大模型友好文本 |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |
|  向量模型API                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | <a href="https://api.jina.ai/v1/embeddings">https://api.jina.ai/v1/embeddings</a> | 将文本/图片转为定长向量       |    |                                                                                             |                                                   |                  |                                                                                             |                                                   |                    |                                                                                             |                                                                                   |              |                      |             |         |                         |

<http://serpapi.com/>

APIs

Explore all search engines we support or check out our complete API list.

Google Search API

Google Light Search API

Google AI Mode API

Google AI Overview API

Google Ads Transparency API

Google Autocomplete API

Google Events API

Google Finance API

Google Finance Markets API

Google Flights API

Google Flights Autocomplete API

Google Forums API

Google Hotels API

Google Hotels Autocomplete API

Google Hotels Photos API

Google Hotels Reviews API

Google Images API

Google Images Light API

Google Immersive Product API

Google Jobs API

Google Lens API

Google Local API

Google Local Services API

Google Maps API

Google Maps Autocomplete API

Google Maps Contributor Reviews API

Google Maps Directions API

Google Maps Photos API

Google Maps Posts API

Google Maps Reviews API

Google News API

Google News Light API

Google Patents API

Google Patents Details API

Google Play Books API

Google Play Games API

Google Play Movies API

Google Play Product API

Google Play Store API

Google Related Questions API

Google Reverse Image API

Google Scholar API

Google Scholar Author API

Google Scholar Case Law API

Google Shopping API

Google Shopping Light API

Google Short Videos API

Google Travel Explore API

Google Trends API

Google Trends Autocomplete API

Google Trends Trending Now API

Google Videos API

Google Videos Light API

Amazon Search API

Amazon Product API

Apple App Store API

Apple Maps API

Apple App Store Product API

Apple App Store Reviews API

Baidu Search API

Baidu News API

Bing Search API

Bing Copilot API

Bing Images API

Bing Maps API

Bing News API

Bing Product API

Bing Reverse Image API

Bing Shopping API

Bing Videos API

Brave AI Mode API

DuckDuckGo Search API

DuckDuckGo Light API

DuckDuckGo Maps API

DuckDuckGo News API

eBay Search API

eBay Product API

Facebook Profile API

The Home Depot Search API

The Home Depot Product API

The Home Depot Reviews API

Naver Search API

Naver AI Overview API

OpenTable Reviews API

Tripadvisor Search API

Tripadvisor Place API

Tripadvisor Reviews API

Walmart Search API

Walmart Product API

Walmart Reviews API

Yahoo! Search API

Yahoo! Images API

Yahoo! Shopping API

Yahoo! Videos API

Yandex Search API

Yandex Images API

Yandex Videos API

Yelp Search API

Yelp Place API

Yelp Reviews API

YouTube Search API

YouTube Video API

YouTube Video Transcript API

Extra APIs

Status and Error Codes

支持的 API 比较多，中英文来源都支持

<https://serper.dev/>

Playground

Type

Search

Search

Search

Images

Videos

Places

Maps

Reviews

News

Shopping

Image Search (Lens)

Scholar

Patents

Autocomplete

Webpage

New

Results

Code

Credits: 1

Python

Requests

POST

Copy

```
import requests
url = "https://google.serper.dev/search"

payload = {
  "q": "apple inc"
}
headers = {
  'X-API-KEY': 'e8db19259e26593c90e10755ca0b2abe59aabe82',
  'Content-Type': 'application/json'
}

response = requests.request("POST", url, headers=headers, json=payload)

print(response.text)
```

对 Google 支持完善，内容主要为英文

Shell / 虚拟环境

<https://developers.openai.com/api/docs/guides/tools-shell>

<https://developers.openai.com/api/docs/guides/tools-local-shell>

<https://platform.claude.com/docs/en/agents-and-tools/tool-use/bash-tool>


**Shell 工具**它允许 AI 模型在一个完整的终端环境中执行命令。

- 需要确定性计算
- 批量文件处理
- 需要安装依赖包的复杂任务

Python

```
1 from openai import OpenAI
2
3 client = OpenAI()
4
5 response = client.responses.create(
6     model="gpt-5.5",
7     tools=[{"type": "shell", "environment": {"type": "container_aut
8         o"}}],
9     input=[
10         {
11             "type": "message",
12             "role": "user",
13             "content": [
14                 {
15                     "type": "input_text",
16                     "text": "Execute: ls -lah /mnt/data && python --ver
17 sion && node --version",
18                 }
19             ],
20             tool_choice="auto",
21         )
22
23 print(response.output_text)
```

**Computer use**



<https://developers.openai.com/api/docs/guides/tools-computer-use>

<https://help.aliyun.com/zh/agentbay/computeruse>

<https://platform.claude.com/docs/en/agents-and-tools/tool-use/computer-use-tool>

**Computer Use（计算机使用）** 工具让 AI 模型能够像人一样通过图形界面操作软件。与刚才的 Shell 工具（命令行操作）不同，Computer Use 模拟的是鼠标点击、键盘输入、屏幕查看等 GUI 交互。让模型通过**看屏幕截图**→**决定操作**（点击、输入、滚动）→**执行操作**→**再看新截图**的循环，来完成各类 GUI 自动化任务。

- `click` / `double_click` - 鼠标点击
- `scroll` - 滚动
- `type` - 输入文本
- `keypress` - 按键（Enter、Tab 等）
- `wait` - 等待
- `drag` - 拖拽
- `move` - 鼠标移动
- `screenshot` - 请求截图

## Code Interpreter

<https://developers.openai.com/api/docs/guides/tools-code-interpreter>

<https://platform.claude.com/docs/en/agents-and-tools/tool-use/code-execution-tool>

**代码解释器**工具允许模型在沙盒环境中编写和运行 Python 代码，以解决数据分析、编程和数学等复杂领域的问题。它可用于：

- 处理包含各种数据和格式的文件。
- 生成包含数据和图表图像的文件。
- 迭代地编写和运行代码来解决问题——例如，一个模型编写的代码运行失败后，可以不断重写和运行该代码，直到成功。

## Agent 落地案例